

DEFINICIONES DE INFERENCIA CAUSAL

La Wikipedia en español hasta agosto de 2021 no recoge una definición de “Inferencia Causal” (IC). En una búsqueda de julio de 2023 aparecen referencias al “modelo causal de Robin” y en el texto se hace alusión a: “el problema fundamental de la inferencia causal”, entre otras referencias dentro de otros conceptos.

En el diccionario de la Real Academia de la Lengua española, se tiene:
Inferir: Del lat. inferre 'llevar a'.

1. tr. Deducir algo o sacarlo como conclusión de otra cosa. Se infiere de su rostro que está contento.
3. tr. desus. Incluir o llevar consigo algo. Las premisas infieren la conclusión

En inglés la definición de esta fuente (*Wikipedia*, 2021) dice:

“Inferring the cause of something has been described as:

- “...reason[ing] to the conclusion that something is, or is likely to be, the cause of something else”.*
- “Identification of the cause or causes of a phenomenon, by establishing covariation of cause and effect, a time-order relationship with the cause preceding the effect, and the elimination of plausible alternative causes.”**

*“[causal inference](#)”. Encyclopædia Britannica, Inc. Retrieved 24 August 2014

**John Shaughnessy; Eugene Zechmeister; Jeanne Zechmeister (2000). [Research Methods in Psychology](#). McGraw-Hill Humanities/Social Sciences/Languages. pp. Chapter 1 : Introduction. [ISBN 978-0077825362](#). Archived from [the original](#) on 15 October 2014. Retrieved 24 August 2014.

“La inferencia causal se refiere a una disciplina intelectual que considera los supuestos, diseños de estudio y estrategias de estimación que permiten a los investigadores sacar conclusiones causales basadas en datos. Como se detalla a continuación, el término “conclusión causal” que se utiliza aquí se refiere a una conclusión con respecto al efecto de una variable causal (a menudo denominada “tratamiento” en una concepción amplia de la palabra) sobre algunos resultados de interés. La perspectiva dominante sobre la inferencia causal en la estadística tiene fundamentos filosóficos que se basan en la consideración de estados contrafácticos. En particular, considera los resultados que podrían manifestarse dada la exposición a cada una de un conjunto de condiciones de tratamiento. Los efectos causales se definen como comparaciones entre estos “resultados potenciales”. Por ejemplo, el efecto causal de un fármaco sobre la presión arterial sistólica 1 mes después de que ha comenzado el régimen farmacológico (versus sin exposición al fármaco) se definiría como una comparación de la presión sistólica presión arterial que se mediría en este momento dada la exposición al fármaco con la presión arterial sistólica que se mediría en el mismo momento en ausencia de exposición al fármaco. El desafío para la inferencia causal es que generalmente no podemos observar ambos estados: en el momento en que medimos los resultados, cada individuo ha tenido exposición a medicamentos o no”. (Hill & Stuart, 2015, #)

“Ningún libro posiblemente pueda proporcionar una descripción completa de todas las metodologías para inferencia causal a través de las ciencias”. (Hernán & Robins, 2020, # vii).....“Una tarea científica compleja, la inferencia causal se basa en triangular evidencia de múltiples fuentes y en la aplicación de una variedad de enfoques metodológicos”. (Hernán & Robins, 2020, # vii)“Como ser humano, [usted] ya está familiarizado de forma innata con los

conceptos fundamentales de la inferencia causal. Mediante pura existencia, sabe lo que es un efecto causal, comprende la diferencia entre asociación y causalidad, y ha utilizado este conocimiento de manera constante a lo largo de su vida. Si no lo hubiera hecho, estaría muerto. Sin conceptos básicos de causalidad, no habría sobrevivido lo suficiente para leer este capítulo, y mucho menos aprender a leer. Cuando era un niño pequeño, habría saltado directamente a la piscina después de ver que los que lo hicieron pudieron alcanzar el frasco de mermelada. De adolescente, habría esquiado por las pistas más peligrosas después de ver a los que lo hicieron y ganaron un nuevo esquí. Como padre, se habría negado a darle antibióticos a su hijo enfermo después de observar que los niños que tomaron esa medicina no estaban en el parque al día siguiente". (Hernán & Robins, 2020, # 3)

Pearl (Pearl & Mackenzie, 2018, # 3) denomina a la Inferencia Causal como la “nueva ciencia”. La inferencia causal es todo acerca de tomarse en serio la pregunta ¿Por qué? La inferencia causal “ha engendrado un lenguaje matemático simple para articular tanto las relaciones causales que conocemos, así como aquellas que quisiéramos descubrir”.

*“La estadística tradicional es sólida para idear formas de describir datos e inferir parámetros distributivos de la muestra. La **inferencia causal** requiere dos ingredientes adicionales: un lenguaje amigable con la ciencia para articular el conocimiento causal y una maquinaria matemática para procesar ese conocimiento, combinándolo con datos y sacar nuevas conclusiones causales sobre un fenómeno”. (Pearl, 2010, #). En un video de 2021 Pearl define la “nueva ciencia” de Inferencia Causal, como: “Las lógicas y las herramientas para responder preguntas causales (i.e. causar, prevenir, atribuir, discriminar, arrepentir)”.*

En los trabajos de Pearl es evidente una evolución metodológica que va de los “4 Methodological Principles of Causal Inference” (Pearl, 2010, #) a la “Inference Engine” (Pearl & Mackenzie, 2018, # 12) (Pearl, 2021), esta evolución tiene mucho que ver con los usos de la inferencia causal en el campo de la inteligencia artificial, pero también en la incorporación progresiva de elementos de la discusión filosófica sobre el concepto de causalidad que finalmente logra ser integrado en el trabajo científico. Estos principios y su expresión metodológica a manera de una “maquinaria” para hacer inferencias causales se cimientan en el uso de gráficos para representar las relaciones conocidas e hipotéticas entre variables (observadas y no observadas) y en la formulación de estas relaciones en lenguaje matemático mediante modelos estructurados de causalidad. En “The book of why” se señala que muchas personas actualmente la denominan “Causal Revolution”.

El desarrollo de los DAG (gráficos acíclicos direccionados), desde la perspectiva de Pearl, son parte del “lenguaje amigable con la ciencia” que permite que los supuestos teóricos de causalidad ya conocidos por la ciencia queden explicitados en un gráfico en forma de relaciones de variables, unas de asociación y otras de causalidad, mediante el uso de flechas que solo pueden ser direccionadas desde la causa hacia el efecto. Estos gráficos pueden ser sometidos a mecanismos de supresión o inclusión de variables o de valores hipotéticos para chequear la inclusión de sesgos y para identificar relaciones de confusión, mediación y colisión entre variables, lo que los convierte en el mecanismo para articular el procesamiento matemático de las relaciones entre variables hasta aislar las relaciones empíricamente evidentes de las que se puede “inferir causalidad”.

Por otra parte, el desarrollo de los Modelos Causales Estructurales (Structural Causal Models SCM) son la expresión en lenguaje universal de la “maquinaria matemática para

procesar ese conocimiento, combinándolo con datos y sacar nuevas conclusiones causales sobre un fenómeno”. Se construye este andamiaje matemático con bases conceptuales como: do-operator, d-separation y “Do-calculus”

La definición de inferencia causal como un problema matemático que se resuelve a partir de ecuaciones, conlleva un conflicto sobre la simbología que la ciencia ha utilizado para responder las preguntas causales que usan verbos que denotan una asimetría entre la acción y la consecuencia. Usualmente el planteamiento matemático ha recurrido a una igualdad (ecuación) para responder este tipo de preguntas. El lenguaje matemático de las ecuaciones supone atribuir una simetría, expresada por el símbolo de igualdad, a los dos términos de la ecuación; mientras que, en el caso de las preguntas causales, la lógica nos señala una asimetría entre la causa y su efecto, una relación señalada por una flecha que va desde la causa hacia el efecto no un signo de igualdad entre los dos. El signo “igual” (“=”) ha sido dominante en la gramática del trabajo científico.

Este conflicto es más evidente cuando se dividen las preguntas causales en preguntas derivadas de una observación ¿cómo explico lo observado?, preguntas derivadas de una acción ¿qué pasa si se produce una intervención? o preguntas derivadas de un supuesto contrafáctico ¿qué pasa si las cosas se hacen de otra manera? Estas tres preguntas, que representan un cierto orden jerárquico basado en el tipo de información disponible, tienen un correlato en sus respuestas en términos de diferentes sintaxis de probabilidad simple y de probabilidad condicional.

“La inferencia causal va más allá de la predicción al modelar el resultado de las intervenciones y formalizar el razonamiento contrafactual”. (Dablander, 2019)

Se parte del supuesto de que los datos son comparables, que están libres de sesgos o que en caso de haber identificado sesgos, estos pueden tener un tratamiento estadístico. La dificultad de extrapolar los datos (inferencia estadística) de una muestra al universo o de las comparaciones entre estratos de una población o de poblaciones expuestas y no expuestas, reside en la identificación de las relaciones causales en el diseño del estudio, en la recolección de los datos y en el análisis de los mismos. La ciencia durante el siglo XX asumió que las pruebas estadísticas realizadas a los datos, diferenciadas según el procedimiento de recolección de la información era suficiente para garantizar que los hallazgos de un estudio eran un reflejo altamente probable de lo que sucede en toda la población y que si estaban sustentadas en algún supuesto teórico las asociaciones estadísticas encontradas deberían ser causales. Esta noción empezó a ser cuestionada en la segunda mitad del siglo XX y en la tercera década del siglo XXI estos cuestionamientos han derivado en nuevas propuestas de lenguajes matemáticos para su interpretación.

En el libro “Causal Inference, what if” (Hernán & Robins, 2020, # vii), el enfoque es *“la identificación y estimación de efectos causales en poblaciones, esto es, cantidades numéricas que miden los cambios en la distribución de un resultado bajo diferentes intervenciones”*. Esta forma de definir la inferencia causal se declara “agnóstica sobre conceptos metafísicos como causalidad o causa” y dispone de un elaborado instrumental matemático para procesar los cambios observados.

En resumen, la inferencia causal es el puente entre los principios filosóficos y el método científico, que permiten al pensamiento humano definir la causalidad en diferentes formas y para diferentes circunstancias de las relaciones de causalidad, operacionalizando estas ideas en los lenguajes universales: las matemáticas y los gráficos, capaces de dar cuenta eficiente de las modificaciones cuantitativas y cualitativas de las relaciones entre causa y efecto.

Este nuevo campo de interpretación de la causalidad (para las ciencias diferentes a la física), que se declara en ciertos casos agnóstica de los conceptos metafísicos, permanece inaccesible durante la mayor parte de la vida laboral para los cerebros no matemáticos, que representan una alta proporción de la población de profesionales y científicas. Las usuarias con capacidades matemáticas insuficientemente desarrolladas, por su parte, se benefician enormemente de las aproximaciones metafísicas al tema de la causalidad que requieren un rigor lógico elevado, una destreza mental relativamente bien desarrollada al completar los ciclos educativos de mayor nivel. La propuesta aquí es la de cotejar las ideas de causalidad desde la filosofía con los instrumentos matemáticos que usan y desarrollan permanentemente las científicas para hacer inferencia causal. Evidentemente no se propone que exista una identidad mecánica entre estos dos grandes escenarios del desarrollo del pensamiento humano, la propuesta es eminentemente pedagógica y didáctica. La hipótesis sería que la explicación metafísica ofrece un marco de referencia en el que los teoremas matemáticos tienen un escenario de mejor comprensión, a pesar de no lograr llegar al nivel del procesamiento matemático de estos principios, para lo que se necesita conocimientos, habilidades y destrezas que no toda la población posee.

La definición de causalidad debe ser también operacionalizada en términos didácticos y pedagógicos. En el presente trabajo se propone la enseñanza de los DAGs que proporcionan escenarios para una mejor comprensión de los fundamentos de las teorías de la causalidad como regularidad y de la teoría contrafáctica de la causalidad.

Existe también una corriente que niega estas definiciones de inferencia causal y defiende la inferencia estadística que *“idea formas de describir datos e inferir parámetros distributivos de la muestra”*. Los datos adquieren valores mediante procedimientos estadísticos y estos valores pueden ser generalizados a toda la población, respetando las formas de distribución de los datos y las limitaciones por el hecho de haber recurrido a la selección de una muestra. Más allá de eso, al cruzar variables de dos o más estratos de la misma población o comparar las mismas variables en diferentes poblaciones o al someter a una población a una intervención y comparar sus datos con los de una población similar no sometida a la intervención, se producirán nuevos datos y nuevas distribuciones del cruce de las variables que necesitarán mejorados procedimientos para convertirlos en valores inteligibles para todas. La complejidad mayor se presenta cuando los datos estadísticos corresponden a series temporales de observaciones en una misma población o en poblaciones expuestas y no expuestas, los datos adoptarán nuevos tipos de distribuciones y los resultados se medirán en el tiempo transcurrido entre la exposición y el efecto, para lo que se necesita otro arsenal estadístico específico. Estas nuevas cifras podrán ser generalizadas (“inferidas”) al total de la población o por lo menos a poblaciones similares a las que originaron los datos.

Según una conversación con el modelo de lenguaje artificial ChatGPT (13 de marzo de 2023), el siguiente resultado se obtiene en relación a la pregunta sobre la diferencia entre inferencia causal y estimación de los efectos del tratamiento:

“Robins y Hernán argumentan que la inferencia causal es un proceso más amplio y complejo que la simple estimación de los efectos de tratamiento [causa-efecto]. La inferencia causal implica la evaluación de la relación causal entre dos variables, mientras que la estimación de los efectos de tratamiento se refiere específicamente a la medición de la magnitud de la relación causal entre un tratamiento o exposición y un resultado. La diferencia clave entre estos dos conceptos radica en la importancia de los supuestos causales explícitos en la inferencia causal. La inferencia causal requiere la identificación de un conjunto completo de supuestos sobre la causalidad y la evaluación de la validez de estos

supuestos, mientras que la estimación de los efectos de tratamiento sólo requiere la especificación de un modelo estadístico adecuado para estimar la relación causal”.

El debate se completa con argumentos sobre la necesidad de una inferencia causal para todas las ciencias, cuando al parecer algunas ciencias duras se hacen cargo de problemas de la realidad que se interpretan como “leyes de la naturaleza” o situaciones singulares que no requieren ningún tipo de regularidad para ser aceptadas como universales o que siendo regulares solo requieren una formalización en lenguaje universal para ser aceptadas. Es lo que en principio constituye el argumento central de la teoría de la causalidad como singularidad.

“Hay controversias en la filosofía y la filosofía de la ciencia no sólo acerca de cuál (si alguna) explicación de la causalidad es correcta, sino también sobre el papel de la causalidad (y, de manera relacionada, la explicación causal) en varias áreas de la ciencia. Por ejemplo, una corriente influyente del pensamiento sostiene que las nociones causales juegan poco o ningún papel legítimo en la física (...). También ha habido un aumento reciente del interés en [lo que se considera] formas de explicación no causales, no solo en la física sino también en ciencias como la biología. Un tema común (o al menos subyacente) en esta literatura es que la causalidad (y el razonamiento causal) es menos central para gran parte de la ciencia de lo que muchos han supuesto (...). De hecho, existen formas de explicación no causales, pero el razonamiento causal juega un papel central en muchas áreas de la ciencia, incluidas las ciencias sociales, del comportamiento y biológicas, así como en partes de la estadística, la inteligencia artificial y el aprendizaje automático. Filósofos de la ciencia deberían comprometerse con esta literatura en lugar de ignorarla o intentar restar importancia a su importancia.” (Woodward, 2016, #18)