

GLOSARIO DE TÉRMINOS ÚTILES PARA COMPRENDER LA INFERENCIA CAUSAL:

A continuación se expone un listado incompleto de definiciones de términos usados en inferencia causal, elaborado por Chatgpt (entre el 9 de mayo al 24 de agosto de 2023):

1. Algorithmization of counterfactuals: Es el proceso de convertir los conceptos contrafácticos en una forma matemática que pueda ser implementada en un algoritmo para realizar inferencia causal.
2. Average treatment effect (ATE): Es el efecto medio de una intervención en una población.
3. Backdoor criterion: Es un criterio que se utiliza para identificar las variables de confusión en un modelo causal.
4. Bayesian neural networks: Son modelos de redes neuronales que utilizan inferencia bayesiana para realizar inferencia causal. Causal diagram: Es un grafo que representa la estructura causal de un conjunto de variables.
5. Causal inference: Es la inferencia de relaciones causales entre variables a partir de datos observacionales o experimentales.
6. Causal survival analysis: Es el análisis de datos de supervivencia que tiene en cuenta la causalidad de los eventos que pueden influir en la supervivencia.
7. Conditional independence: Es la propiedad de que dos variables son independientes condicionales a una tercera variable en un sistema causal.
8. Consistency: Un supuesto que establece que los resultados observados en un estudio son consistentes con las relaciones causales en la población objetivo.
9. Control of Confounding: El proceso de gestionar o ajustar variables de confusión en un análisis causal para reducir la posibilidad de inferencias incorrectas.
10. Counterfactual: Es la comparación entre lo que sucedió y lo que habría sucedido si se hubieran dado diferentes circunstancias.
11. Data fusion: Es el proceso de combinar datos de diferentes fuentes para mejorar la inferencia causal.
12. Directed Acyclic Graph (DAG): Un diagrama que representa gráficamente las relaciones causales entre variables mediante nodos y flechas dirigidas, sin formar ciclos. Es una herramienta útil para visualizar y comprender la estructura causal de un problema.
13. Do calculus: Es un conjunto de reglas matemáticas para la inferencia causal basada en la manipulación de variables.
14. Do operator: Es un operador matemático que representa la manipulación causal de una variable.
15. D-Separation: Es un método para determinar si dos variables en un grafo causal son condicionalmente independientes.
16. Effect Modification: Ocurre cuando el efecto de una variable independiente en una variable dependiente varía según los niveles de otra variable.
17. Exchangeability: La propiedad que permite considerar a dos o más individuos o grupos como intercambiables en términos de asignación de tratamientos, lo que es esencial para la inferencia causal.
18. External validity: Es la medida en que los resultados de un estudio pueden generalizarse a otras poblaciones, contextos o situaciones.
19. Frontdoor criterion: Es un criterio que se utiliza para identificar las variables instrumentales en un modelo causal.
20. Generalizability: Es la capacidad de un resultado causal de aplicarse a una amplia gama de poblaciones y contextos.
21. Identifiability: La capacidad de estimar los parámetros causales de un modelo a partir de los datos observados.
22. Individual Causal Effects: Los efectos causales de una variable en un individuo en particular, en contraste con los efectos promedio en una población. Individual

- treatment effect (ITE): Es el efecto de una intervención en un individuo específico.
23. Internal Validity: Se refiere a la validez de una relación causal encontrada en un estudio, asegurando que los cambios observados en la variable independiente realmente causaron los cambios en la variable dependiente y no fueron influenciados por otras variables no controladas.
 24. IP Weighting (Inverse Probability Weighting): Un método que ajusta los pesos de las observaciones para compensar el sesgo de selección y hacer que la muestra se asemeje más a la población general.
 25. Matching: Un método que empareja a los individuos en grupos tratados y no tratados que son similares en términos de variables de confusión, para controlar el sesgo de selección.
 26. Measurement Bias: Un sesgo que surge cuando las mediciones de variables son inexactas o sistemáticamente incorrectas, lo que puede afectar las inferencias causales.
 27. Mendelian Randomization: Un enfoque que utiliza variantes genéticas aleatorias como instrumentos para estimar relaciones causales entre variables no manipulables.
 28. Monotonicity: Un supuesto en inferencia causal que establece que no puede haber casos en los que una intervención cause un efecto negativo para algunos individuos y un efecto positivo para otros en el mismo contexto.
 29. Motivation: Es la justificación teórica para una hipótesis causal basada en el conocimiento previo del sistema causal subyacente.
 30. P-Benefit: Un término acuñado por Judea Pearl para referirse a la ganancia potencial de cambiar una política o acción basada en la inferencia causal, en contraposición a simplemente observar asociaciones en los datos.
 31. P-Harm: Similar al concepto de P-Benefit, pero se refiere a los posibles daños causados por cambiar una política o acción en función de la inferencia causal.
 32. Positivity: Un supuesto que asegura que todos los individuos tengan una probabilidad positiva de recibir diferentes niveles de tratamiento.
 33. Potential Outcome: En el marco del enfoque de potenciales resultados, se refiere a los resultados que habrían ocurrido bajo diferentes condiciones de tratamiento o exposición.
 34. Propensity Scores: Puntajes que estiman la probabilidad de recibir un tratamiento o exposición dado un conjunto de variables de control, utilizados para ajustar sesgos en estudios observacionales.
 35. Random Variability: Las fluctuaciones naturales o aleatorias en los datos que pueden afectar las relaciones observadas entre variables y la inferencia causal.
 36. Stratification: La estratificación de una población en subgrupos homogéneos con respecto a ciertas variables, lo que puede ayudar a controlar variables de confusión en el análisis causal.
 37. Treatment effect: Es el efecto de una intervención en una variable de resultado.
 38. Treatment heterogeneity and personalized medicine: Es el estudio de la variación en los efectos de tratamiento entre individuos y la identificación de subgrupos de pacientes que responden mejor a un tratamiento en particular.
 39. Testable implications: Son las consecuencias observables y medibles de una hipótesis causal que pueden ser utilizadas para verificar la validez de la hipótesis.
 40. Transportability: Es el proceso de aplicar un resultado causal de un contexto a otro contexto diferente, teniendo en cuenta las diferencias entre los dos contextos.
 41. Testability: La capacidad de una hipótesis causal de ser probada a través de experimentos controlados o métodos observacionales.

42. Selection Bias: Un tipo de sesgo en el que las muestras recopiladas para un estudio no son representativas de la población general, lo que puede llevar a inferencias causales incorrectas.