

## LOS NUEVOS IDIOMAS DE LA DE-CONFUSIÓN

Para proponer un problema de investigación y las relaciones entre las variables, se examinarán los conocimientos previos de cada una de las variables. Las confluencias representan la posible relación causal entre A y C, teniendo a B como mediadora, confusora o colisionadora. Pero en la realidad B no será necesariamente una sola variable, B se refiere a:

- Todas las variables que la teoría ha logrado identificar anteriormente como parte de las cadenas causales y fuera de estas cadenas, que configuran la relación causal principal entre A y C.
- Todas las variables que podrían estar relacionadas y de las que todavía no existe una medición.
- Las variables desconocidas que contrafacticamente sería plausible incluir en el planteamiento de un problema de investigación.

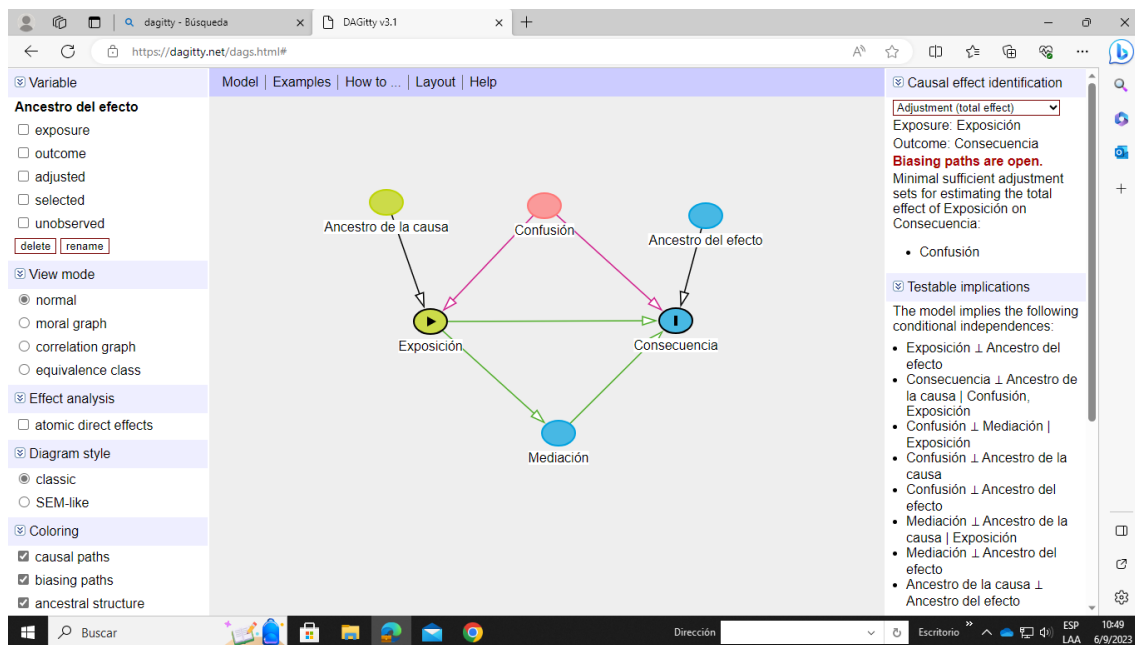
En este contexto, se hace indispensable encontrar formas de expresar las ideas de tal forma que todas las personas que revisen un concepto, un diseño de una investigación, los resultados de investigaciones realizadas entiendan de una forma similar:

- los DAGs y
- los SCM

La traducción literal de "Directed Acyclic Graphs" podría ser "gráficos acíclicos direccionados", pero aquí se propone una traducción más bien de contenido: gráficos unidireccionales de trayectoria causal (GUTC), puesto que sus ancestros son los gráficos del "path analysis" y la orientación de las trayectorias causales es siempre desde la causa hacia el efecto. Mientras que la traducción literal de "Structural Causal Models" sería modelos estructurales de causalidad, según BARD también se puede traducir como "modelos de ecuaciones estructurales" que es una definición de tipo matemático.

La representación gráfica de las relaciones entre las variables implica la direccionalidad desde la causa hacia el efecto (prioridad temporal), la ausencia de una flecha que relacione dos variables ("independencia") habla mucho sobre el supuesto teórico de que entre esas dos variables no hay una relación causal (conjunción constante y contigüidad espacial). La palabra "acíclico" implica la noción de que debemos evitar lo más posible tener flechas entre las variables que vayan "hacia atrás" en las relaciones causales principales (cadenas causales paso a paso). Estos DAG/GUTC no son mapas mentales descriptivos de la teoría sobre un tema concreto de interés científico, son representaciones gráficas de modelos de pensamiento que deberán ser procesados mediante el método científico. En estos gráficos se pueden encontrar las tres **confluencias** descritas por Pearl como las células germinales de las redes bayesianas, las que en innumerables combinaciones posibles en un DAG/GUTC (Suttorp et al., 2015, #) (Shrier & Platt, 2008, #) se convertirán en una matriz para identificar qué variables deben ser consideradas de confusión, de mediación y colisionadoras. La consecuencia es identificar el tipo de procesamiento estadístico y matemático que se requiera para sustentar la relación causal principal y las otras relaciones causales involucradas en su justa dimensión. El desarrollo de los procedimientos estadísticos que ofrecen la opción de poner en evidencia el tipo de relación, el valor de las variables y las distribuciones que adquieren los datos tanto crudos como los del resultado de las comparaciones y relaciones entre variables. En este lenguaje y en su procesamiento matemático se pueden incluir variables "no

medidas” o desconocidas y asignarles valores en función de criterios de probabilidad. También es posible eliminar variables o eliminar flechas, lo que permitirá realizar cálculos estimados en condiciones diferentes a las de los datos efectivamente recolectados. Finalmente, se puede “transportar” datos de diferentes tipos de estudio (observacionales o experimentales) originados en diferentes poblaciones y elaborar un SCM a partir de un DAG.



(Textor et al., 2016, #)

En el gráfico se observan las relaciones de causalidad más simples o básicas, existen más relaciones. Una noción crucial en la elaboración e interpretación de los DAG/GUTC, es la diferencia entre las trayectorias causales y las trayectorias no causales.

Las trayectorias causales son las que van desde la exposición y terminan en la consecuencia, sea directamente o sea mediante una cadena causal secuencial. En este tipo de trayectorias se deben reconocer las confluencias de mediación directa e indirecta. En estos casos es necesario identificar este tipo de relaciones desde los supuestos teóricos disponibles o hipotetizados puesto que su tratamiento algebraico se basa en el uso de la fórmula de la mediación (puerta de enfrente) que procura diferenciar si es que existe un efecto directo o se trata de un efecto indirecto. Para este tipo de cadenas secuenciales de causalidad el procesamiento matemático debe evitar bloquear la relación o realizar ajustes similares a los que se realizan para el control de confusión, puesto que estos alterarían la relación de causalidad controlando por lo que sí es una relación de causalidad.

Las trayectorias no causales son las que se relacionan tanto con la consecuencia como con la exposición en forma de tenedor o relación de confusión, esta doble relación o causa común producirá una covariación entre la exposición y la consecuencia que si no es una relación de causalidad sino una relación de asociación podría dar un resultado estadístico que haga que una relación de asociación se interprete como una de causalidad. En estos casos es necesario realizar los ajustes algebraicos correspondientes mediante la fórmula de la puerta de atrás para controlar el efecto de confusión, bloqueando la interacción de la variable de confusión con la de exposición.

Pearl sugiere que para introducir el tema de los DAGs se utilice la paradoja de Simpson, que es un ejemplo de la dificultad para la identificación de la causalidad al tomar en cuenta las variables de confusión.

En una conversación con BARD se obtiene lo siguiente:

Pregunta: En el marco de la inferencia causal, proporcione un ejemplo de contenido epidemiológico de la "paradoja de Simpson" y resalte la utilidad de utilizar los DAG para poner en evidencia los supuestos de causalidad sobre los que se basa la explicación de un fenómeno causal

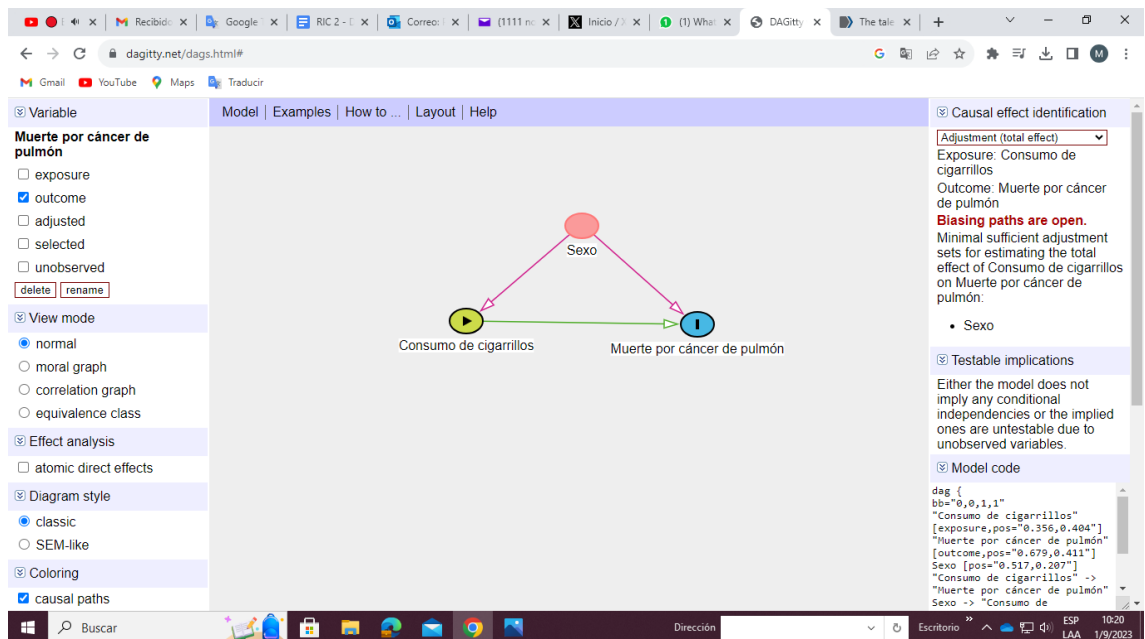
Respuesta de BARD:

*En el marco de la epidemiología, un ejemplo clásico de la paradoja de Simpson es el estudio que se realizó en 1964 en el Reino Unido para evaluar la relación entre la mortalidad por cáncer de pulmón y el consumo de cigarrillos. El estudio encontró que, a nivel agregado, la mortalidad por cáncer de pulmón era mayor en las personas que fumaban más cigarrillos. Sin embargo, al analizar los datos por sexo, se encontró que la mortalidad por cáncer de pulmón era mayor en las mujeres que fumaban menos cigarrillos, y menor en los hombres que fumaban más cigarrillos.*

*Este resultado aparentemente contradictorio se puede explicar por la presencia de una variable de confusión, que en este caso es el sexo. Las mujeres suelen fumar menos cigarrillos que los hombres, y también tienen una mayor esperanza de vida. Esto significa que, a nivel agregado, el grupo de mujeres que fuman más cigarrillos está compuesto por personas más jóvenes, que son menos propensas a morir por cáncer de pulmón. En cambio, el grupo de hombres que fuma menos cigarrillos está compuesto por personas mayores, que son más propensas a morir por cáncer de pulmón.*

*En este ejemplo, la paradoja de Simpson se produce porque no se tiene en cuenta la variable de confusión, que es el sexo. Si se hubiera tenido en cuenta esta variable, se habría encontrado que el consumo de cigarrillos es un factor de riesgo para el cáncer de pulmón, independientemente del sexo.*

*Los diagramas de grafos causales (DAG) son una herramienta útil para poner en evidencia los supuestos de causalidad sobre los que se basa la explicación de un fenómeno causal. En el caso del ejemplo de la paradoja de Simpson, el DAG correspondiente sería el siguiente:*



*En este DAG, el consumo de cigarrillos es la variable independiente, la muerte por cáncer de pulmón es la variable dependiente, y el sexo es una variable de confusión. El DAG muestra que el consumo de cigarrillos tiene un efecto causal sobre la muerte por cáncer de pulmón, pero que este efecto está moderado por el sexo.*

*En conclusión, la paradoja de Simpson es una situación en la que una relación causal observada a nivel agregado se invierte cuando se consideran los datos por grupos. Este fenómeno puede producirse por la presencia de variables de confusión, que son variables que están asociadas tanto con la variable independiente como con la variable dependiente. Los DAG son una herramienta útil para identificar las variables de confusión y, por lo tanto, para evitar la paradoja de Simpson.*

Gran parte de este debate científico y filosófico se ha escenificado en variadas temáticas, como la forma de recolectar la información, la forma de organizarla una vez recolectada, la forma de procesarla mediante pruebas estadísticas, la forma de interpretar los resultados y la forma de aplicar esos resultados en la actividad cotidiana de la sociedad. El control de confusión opera en todos estos niveles, mediante variadas herramientas. En el proceso de evolución de la causalidad en la ciencia, uno de los hitos que todavía ocupan la atención de filósofos y científicos es el ajuste por las variables de confusión.

*Los gráficos acíclicos dirigidos (DAG) son representaciones visuales de supuestos causales que se utilizan cada vez más en la epidemiología moderna. Pueden ayudar a identificar la presencia de factores de confusión para la pregunta causal en cuestión. Este enfoque estructurado sirve como una ayuda visual en la discusión científica al hacer explícitas las relaciones subyacentes. (Suttorp et al., 2015, #)*

Los DAG se han convertido recientemente en una herramienta poderosa para avizorar las variables de un estudio que actuarán como potenciales confusores y para analizar el control por variables de confusión en estudios publicados. Además se puede hacer un control de confusión desde el diseño del estudio mediante el uso de estos gráficos.

*Dado un DAG causal, el concepto de confusión es absoluto, mientras que el de variable de confusión es relativo..... En un DAG causal, una trayectoria de puerta trasera entre el tratamiento y el resultado sería un camino no causal entre el tratamiento y el resultado que permanece incluso si se eliminan todas las flechas que apuntan del tratamiento a otras variables (los descendientes del tratamiento). Es decir, el camino tiene una flecha que apunta al tratamiento. (Hernán & Robins, 2020, # 83)*

Una propiedad interesante de los diagramas causales reside en el hecho de que hacen posible identificar tanto los sesgos de confusión como las variables que pueden resolver este efecto tanto sobre la exposición como sobre la consecuencia. Se trata de identificar las variables precisas que deben ser controladas matemáticamente para eliminar el efecto de confusión de la relación matemática entre la causa y el efecto (i.e. exposición y consecuencia). Se ha venido dando una situación en los estudios científicos en la que los autores deciden controlar/ajustar por la mayor parte de variables relacionadas con la causa y el efecto, lo que terminará dañando irremediablemente el estudio y sus conclusiones. (Tennant et al., 2021, #)

En la actualidad se dispone de software gratuito que permite elaborar un DAG (Textor et al., 2016, #), incorporando una completa serie de opciones de variables y realizando la identificación automática de las variables que cumplen los criterios de confusión, las confluencias de tipo colisión y mediación y las variables que son ancestros de la causa y ancestros del efecto.

Estos diagramas de asociación de variables se convierten en una suerte de experimentos de pensamiento que permiten modificar el gráfico para evaluar la robustez de los supuestos en las relaciones causales que se procuran estudiar. Se pueden hacer incluso cálculos matemáticos con valores observados y extrapolados de otras fuentes o simplemente asignados a manera de prueba, de tal forma que los resultados con datos no reales permitan hacer ajustes a los supuestos teóricos y plantear nuevas hipótesis. Se ven también en la literatura ejemplos de revisiones de trabajos anteriores mediante estos diagramas causales. Adicionalmente, otra ventaja de la elaboración de un diagrama causal para el análisis de un conocimiento ya establecido o para el planteamiento de una investigación original, es la introducción en el gráfico de una intervención que potencie o suprima relaciones previamente conocidas o puramente experimentales, incluso simplemente hipotéticas. Mediante la metodología de los diagramas causales se puede simular el efecto de una intervención y elaborar modelos matemáticos que permitan mejorar el planteamiento de una investigación.

*En la epidemiología del siglo XXI, la “inferencia causal” ha llegado a representar un enfoque específico, centrado principalmente en el razonamiento contrafactual y de resultados potenciales y en el uso de representaciones particulares, como los gráficos acíclicos dirigidos (DAG) y las redes causales bayesianas. En este ensayo, sugerimos que en epidemiología ningún enfoque causal debería impulsar las preguntas formuladas o delimitar lo que se considera evidencia útil... (i) limitar quién y qué puede considerarse una “causa”, reduciendo así el alcance del campo; y (ii) conducir a inferencias causales erróneas, especialmente si los supuestos biológicos y sociales clave sobre los parámetros están mal concebidos, lo que podría causar daños. (Krieger & Davey Smith, 2016, #)*

Pearl resalta además el papel de los DAG/ en el abordaje de datos faltantes:

*Para explicar las virtudes de los gráficos en problemas de datos faltantes, esto es lo que escribimos en nuestro artículo: "La transparencia asociada con los modelos gráficos surge de tres factores. Primero, los gráficos sobresalen en codificar y detectar relaciones de independencia condicional, superando con creces la capacidad de intuición humana. En segundo lugar, todos los supuestos están codificados causalmente, reflejando la forma en que los investigadores almacenan el conocimiento científico cualitativo; no se requieren juicios directos de independencias condicionales, ya que estos pueden leerse en la estructura del gráfico. Finalmente, el objetivo final de todos los supuestos es para codificar "las razones de la falta", que es un concepto causal, no estadístico". Hemos agregado este párrafo para apaciguar a un crítico que afirmó: "No necesito gráficos para pensar en independencias condicionales". ¡Sí, revisor, lo necesitas! twJP27ago22*

En una conversación con BARD se obtienen las siguientes definiciones de los DAGs

Pregunta: Proporcione una definición detallada de "Directed acyclic graphs" en el marco de la inferencia causal y con base en las definiciones de Judea Pearl

Respuesta de BARD:

*En el marco de la inferencia causal, los diagramas acíclicos dirigidos (DAGs) son una herramienta gráfica que representa las relaciones causales entre variables. Los DAGs se utilizan para modelar los mecanismos subyacentes a los datos, lo que permite a los investigadores comprender mejor las causas y los efectos de los fenómenos.*

*Según Judea Pearl, un destacado investigador en el campo de la inferencia causal, un DAG es un gráfico en el que cada nodo representa una variable y cada flecha representa una relación causal. Los DAGs se caracterizan por ser acíclicos, lo que significa que no hay ciclos de causalidad.*

*Los DAGs se pueden utilizar para representar una variedad de relaciones causales, incluidas las relaciones directas, indirectas y mediadas. Una relación causal directa se produce cuando una variable causa directamente otra variable. Una relación causal indirecta se produce cuando una variable causa otra variable a través de una tercera variable. Una relación causal mediada se produce cuando una variable causa otra variable a través de una serie de variables intermedias.*

*Los DAGs se pueden utilizar para realizar una variedad de tareas de inferencia causal, incluida la identificación de variables causales, la evaluación de la fuerza de las relaciones causales y la identificación de variables de confusión.*

*A continuación, se presentan algunos ejemplos de cómo se pueden utilizar los DAGs en el marco de la inferencia causal:*

- Un investigador puede utilizar un DAG para modelar la relación causal entre el tabaquismo y el cáncer de pulmón. El DAG podría mostrar que el tabaquismo causa directamente el cáncer de pulmón, pero también podría mostrar que el tabaquismo causa indirectamente el cáncer de pulmón a través de otras variables, como la exposición al humo de segunda mano.*
- Un médico puede utilizar un DAG para evaluar el riesgo de que un paciente desarrolle una enfermedad determinada. El DAG podría mostrar que el paciente tiene un mayor riesgo de desarrollar la enfermedad si tiene ciertos factores de riesgo, como la edad, el sexo o el historial familiar.*

- *Un gobierno puede utilizar un DAG para evaluar la efectividad de una política pública. El DAG podría mostrar que la política pública causa directamente un cambio en el comportamiento, pero también podría mostrar que la política pública causa indirectamente un cambio en el comportamiento a través de otras variables, como los cambios en los precios o la disponibilidad de productos.*

*Los DAGs son una herramienta poderosa que puede ayudar a los investigadores a comprender mejor las causas y los efectos de los fenómenos.*

La misma pregunta realizada a CHATGPT 3.5

Proporcione una definición detallada de "Directed acyclic graphs" en el marco de la inferencia causal y con base en las definiciones de Judea Pearl

Respuesta de ChatGPT

*En el marco de la inferencia causal y basado en las definiciones de Judea Pearl, los "Directed Acyclic Graphs" (DAGs), que se traducen como "Grafos Dirigidos Acíclicos" en español, son representaciones gráficas de relaciones causales entre variables en un sistema. Estos grafos se utilizan para modelar y comprender la estructura causal de un conjunto de variables, lo que es fundamental para abordar preguntas relacionadas con la causalidad en ciencias como la epidemiología, la economía, la inteligencia artificial y otras disciplinas.*

*A continuación, proporciono una definición detallada de los DAGs en el contexto de la inferencia causal según las definiciones de Judea Pearl:*

*Grafos Dirigidos (Directed Graphs): Un DAG es un tipo especial de grafo dirigido, lo que significa que consta de nodos (vértices) conectados por flechas direccionales llamadas arcos. Cada nodo representa una variable (por ejemplo, una característica o una condición), y las flechas indican la dirección de la influencia causal entre las variables.*

*Acíclicos (Acyclic): La característica crucial de un DAG es que no contiene ciclos. En otras palabras, no es posible seguir una secuencia de arcos y volver al mismo nodo a través de una serie de conexiones causales. Esta propiedad de aciclicidad es fundamental porque refleja la intuición de que una causa no puede preceder a su efecto en el tiempo.*

*Relaciones Causales: Los arcos en un DAG representan relaciones causales. Un arco que va desde el nodo A al nodo B indica que A causa o influye en B. Por lo tanto, la dirección de los arcos en el grafo es esencial para capturar la dirección de las relaciones causales, lo que es una característica distintiva de los DAGs en comparación con otros tipos de gráficos.*

*Modelado de Incertidumbre: Los DAGs también pueden incorporar nodos latentes (variables ocultas) para modelar la incertidumbre y factores desconocidos que pueden influir en las variables observadas. Esto permite capturar relaciones causales más complejas y realistas en situaciones en las que no se conocen todas las variables relevantes.*

*Inferencia Causal: Una vez que se ha construido un DAG que representa la estructura causal de un sistema, se pueden realizar inferencias causales utilizando métodos formales. Estos métodos permiten responder preguntas como "¿Cuál es el efecto causal de A en B, teniendo en cuenta las otras variables intervinientes?", lo que es esencial para comprender las implicaciones causales en diversas aplicaciones.*

*En resumen, los Directed Acyclic Graphs (DAGs) son herramientas gráficas poderosas para modelar y analizar relaciones causales en sistemas complejos.*

*Siguiendo las definiciones de Judea Pearl, estos grafos dirigidos y acíclicos capturan la estructura causal de manera explícita y permiten realizar inferencias causales precisas, lo que los convierte en una herramienta esencial en la inferencia causal y la investigación científica en general.*

Varias autoras coinciden en que mientras mejor desarrollado está el DAG/GUTC la identificación de las necesidades de procesamiento matemático y estadístico es más precisa y la elaboración de un SCM/MCE responde adecuadamente a los objetivos planteados en un estudio. La necesidad de elaboración de los DAG/GUTC es mayor cuanto más complejo o controversial sea el planteamiento en estudio, a su vez para temas de menor complejidad posiblemente la identificación de las relaciones entre variables causal, de confusión, de mediación o de colisión no sea tan relevante. En el “Libro del Porqué” (Pearl & Mackenzie, 2018, # 219), capítulo 7, se pueden encontrar mecanismos para responder preguntas de investigación utilizando el “do-calculus”.

El nuevo panorama pone de manifiesto la utilidad y la función de la elaboración de los modelos estructurales de causalidad (Structural Causal Models) basados en supuestos teóricos sólidos y sometidos a un riguroso proceso de validación para encontrar los sesgos de varios tipos que se habrán introducido en su construcción para la demostración operativa de una inferencia causal. Estos modelos matemáticos iniciaron su evolución con la puesta en evidencia hace más de 100 años de que los modelos de regresión son “ciegos a la causalidad”, las variables se correlacionan con el mismo valor independientemente de cuál de ellas está en el eje de las X o de las Y. Pearl nos relata que posteriormente apareció el Path Analysis que fue la primera forma de análisis estructural que además usó un gráfico para poner en evidencia las relaciones entre las variables de tal forma que las relaciones causales de antecendencia y variación concomitante sean visibles tanto durante la recolección de los datos como al momento del análisis estadístico. Esta metodología quedó relegada a un largo segundo plano durante buena parte del siglo XX y hacia el final del siglo se redescubrió para formar parte de la evolución que conduce a la propuesta de los modelos causales estructurales en los que se retoma el uso de una representación gráfica de las relaciones causales entre variables y un elaborado procesamiento estadístico que permite incluso el tratamiento de relaciones causales contrafácticas que hasta este momento solo habían sido posibles mediante el ensayo aleatorio controlado. Pearl señala que tanto con los gráficos como con las ecuaciones de los modelos causales, se consigue “usar datos observacionales y experimentales para extraer información acerca de escenarios contrafácticos”

Esto comienza a ser evidente hace unas cuatro décadas, cuando el postulado original del teorema de Bayes, a saber: ¿cuál es la probabilidad de que se presente A *dado que* se conoce que B se ha producido o se conoce la prevalencia de B en la población?, se actualiza con una nueva variante que postula: ¿cuál es la probabilidad de que se presente A *dado que* **se induce** el apareamiento de B en la población? Este último postulado es el leitmotiv de los estudios experimentales (EAC/RCT), esto es lo que supuestamente garantiza la aleatorización, lo que sumado al manejo estadístico de la incertidumbre que se produce en la distribución de cada variable en la población y la distribución de la interacción entre dos o más variables al realizar una prueba estadística, han configurado la potencia de los estudios aleatorios con intervención.

La probabilidad de que se presente A *dado que* **se induce** intencionalmente la acción de B en la población, es lo que constituye el DO-operator (operador-intervención), si esta probabilidad es mayor que la probabilidad simple de que A se produzca *dado que* conocemos el valor de B, entonces hay una fracción atribuible a la intervención que con seguridad tiene una explicación causal.



## DO-OPERATOR

*Esta característica de invariancia (una cantidad que permanece constante durante la ejecución de un algoritmo dado) nos permite usar ecuaciones estructurales como base para modelar efectos causales y contrafácticos. Esto se hace a través de un operador matemático llamado do (x) que simula intervenciones físicas eliminando ciertas funciones del modelo, reemplazándolas por una constante  $X = x$ , manteniendo el resto del modelo sin cambios. (Pearl, 2010, #). El Do-operator "Nos brinda formas científicamente sólidas de determinar los efectos causales a partir de estudios no experimentales, que desafían la supremacía tradicional de los EAC/RCT. tales estimaciones causales producidas por estudios observacionales pueden ser etiquetadas como "causalidad provisional", es decir, causalidad supeditada al conjunto de supuestos que anuncia nuestro diagrama causal. Es importante que no tratemos estos estudios como ciudadanos de segunda clase: tienen la ventaja de realizarse en el hábitat natural de la población objetivo, no en el entorno artificial de un laboratorio, y pueden ser "puros" en el sentido de no estar contaminado por cuestiones de ética o viabilidad" (Pearl & Mackenzie, 2018, # 132)*

Los modelos causales estructurales son representaciones matemáticas de las relaciones causales entre variables. Estos modelos describen cómo las variables influyen y se relacionan entre sí en un sistema causal. Utilizan diagramas de causalidad para visualizar las relaciones causales. Según ChatGPT:

- *D-Separation (D-Separación): D-Separación es un concepto utilizado en modelos causales estructurales para determinar si dos conjuntos de variables son condicionalmente independientes dada una tercera variable. Se basa en las propiedades del grafo causal asociado al modelo para determinar las dependencias y las independencias condicionales.*
- *Do Operator (Operador Do): El operador "do" [operador-intervención] se utiliza en inferencia causal para denotar la intervención activa sobre una variable en un modelo causal estructural. Se utiliza para indicar que una variable se establece o se fija a un valor específico para analizar los efectos causales que resultan de esa intervención.*
- *Do Calculus (Cálculo Do): El cálculo Do [cálculo-intervención] es un marco teórico y un conjunto de reglas que se utilizan para realizar inferencia causal en modelos causales estructurales. Estas reglas permiten inferir relaciones causales a partir de observaciones y manipulaciones realizadas en el modelo. El cálculo Do proporciona un conjunto de reglas algebraicas que permiten derivar identidades y ecuaciones que describen las relaciones entre variables después de aplicar intervenciones.*

*En resumen, los modelos causales estructurales proporcionan una representación matemática de las relaciones causales entre variables. El concepto de D-Separación se utiliza para determinar las independencias condicionales en estos modelos. El operador Do se utiliza para denotar intervenciones activas en variables, y el cálculo Do proporciona un marco teórico y reglas para realizar inferencia causal a partir de observaciones y manipulaciones en los modelos causales estructurales.*

A continuación, se presenta una matriz comparativa de la propuesta de la inferencia causal utilizando conceptos como d separation, do operator y do calculus, en

contraposición a posibles interpretaciones frecuentistas de los mismos, realizada por ChatGPT:

<i>Concepto / Enfoque</i>	<i>Inferencia causal</i>	<i>Interpretación frecuentista</i>
<i>d separation</i>	<i>Se utiliza para identificar qué variables son necesarias para ajustar en un modelo causal. Se basa en la teoría de grafos dirigidos y permite identificar las variables que bloquean el camino causal entre dos variables de interés.</i>	<i>No tiene una interpretación directa en el enfoque frecuentista, ya que este enfoque no utiliza modelos causales ni gráficos dirigidos.</i>
<i>do operator</i>	<i>Se utiliza para indicar la intervención en una variable, es decir, para establecer qué pasaría en un sistema causal si una variable se modifica a un valor específico. Permite estimar los efectos causales de las intervenciones.</i>	<i>No tiene una interpretación directa en el enfoque frecuentista, ya que este enfoque se enfoca en estimar la probabilidad de un evento a partir de la frecuencia de ocurrencia en una muestra.</i>
<i>do calculus</i>	<i>Es un conjunto de reglas matemáticas que permiten manipular modelos causales para obtener estimaciones de los efectos causales de las intervenciones. Se utiliza para calcular la respuesta causal a las intervenciones en modelos causales.</i>	<i>No tiene una interpretación directa en el enfoque frecuentista, ya que este enfoque se enfoca en la probabilidad de un evento dado el número de ocurrencias en una muestra.</i>